Buku Panduan Rekayasa Sistem: Mekanisme Web Crawler, Arsitektur Anti-Bot, & Harvester Finansial Kecepatan Tinggi

Kompilasi Pengetahuan Mendalam Berdasarkan Pengalaman Empiris Produksi:
AITF Crawler Engine (Mas Anjas), **Bot KOMDIGI v1.1**, **CommunitEyes Pro SNA**, **Polymarket Arbitrage Harvester**, dan **Memecoin DEX/Solana Sniping Bot (VPS Dublin)**

Penulis: Naufal Halim | **Spesialisasi:** Autonomous Systems & Data Engineering | **Tanggal:** Oktober 2026

Abstract

Dokumen komprehensif ini dirancang sebagai buku panduan teknis (*engineering handbook*) untuk mempelajari dan mendalami spektrum rekayasa pengambilan data (*data harvesting*) dan otomasi peramban modern. Bertolak dari repositori dan sistem riil—mulai dari perayapan korpus teks berskala besar untuk dataset *Continual Pre-Training* (CPT) LLM, pembongkaran tantangan CAPTCHA/WAF otonom tanpa pihak ketiga, pemanenan graf jejaring sosial dengan emulasi biometrik manusia, hingga penyerapan buku pesanan pasar prediksi latensi rendah (*sub-20ms*) dan pemantauan likuiditas *mempool* terdesentralisasi—dokumen ini mengupas secara tuntas: (1) mekanisme arsitektural di balik tiap sistem, (2) spektrum senjata sistem deteksi anti-bot modern (analisis IP, sidik jari TLS/JA4, kebocoran CDP, sidik jari Canvas/WebGL, hingga biometrik kursor dan ketikan), (3) teknik mitigasi dan penembusan teruji, (4) komplikasi riil lapangan dan solusinya, serta (5) integrasi agen kognitif otonom (**Hermes Agent**) dan gerbang validasi deterministik berlatensi kilat (**JEV TypeSafe AI**).

Contents

1 Taksonomi & Spektrum Arsitektur Harvester Modern **3**

2 Lanskap Sistem Pertahanan Anti-Bot Modern (*The Defender's Weaponry*) **4**
2.1 Tingkat 1: Reputasi Jaringan & Klasifikasi IP 4
2.2 Tingkat 2: Sidik Jari Protokol & TLS (JA3, JA4, HTTP/2) 4
2.3 Tingkat 3: Sidik Jari Lingkungan Peramban (*Browser Environment Fingerprinting*) 5
2.4 Tingkat 4: Tantangan Kriptografi & Proof-of-Work (Cloudflare Turnstile) 5
2.5 Tingkat 5: Biometrik & Telemetri Perilaku (*Behavioral Telemetry*) 5

3 Taktik & Rekayasa Penembusan Teruji (*The Attacker's Playbook*) **6**
3.1 Taktik 1: Subprocess Chrome CDP Isolation (Pelajaran dari Bot KOMDIGI) 6
3.2 Taktik 2: Virtual Framebuffer (`Xvfb`) & Non-Headless di VPS (Pelajaran dari AITF Mas Anjas) 7
3.3 Taktik 3: Emulasi Biometrik Manusia & Kurva Bezier (Pelajaran dari CommunitEyes) 7
3.4 Taktik 4: Manajemen Sesi & Injeksi Cookie Persisten (`x_state.json`) 7

3.5 Taktik 5: Vision LLM Triage Chain untuk CAPTCHA Visual (Pelajaran dari Bot KOMDIGI) 7

4 Rekayasa Harvester Finansial Latensi Rendah (VPS Dublin) 9
4.1 Strategi Penempatan Geografis & Jaringan (Kasus VPS Dublin) 9
4.2 Arsitektur Ingesti Dual-Stream Polymarket 9
4.3 Pemanenan Likuiditas Mempool Solana & Pertahanan Anti-MEV 10

5 Komplikasi Lapangan & Solusi Praktis (*Battle Scars & Fixes*) 11
5.1 Tabel Diagnostik Masalah & Solusi Rekayasa 11
5.2 Pembedahan Masalah Spesifik & Solusi Kode 11
5.2.1 1. Algoritma Exponential Backoff dengan Full Jitter 11
5.2.2 2. Penanganan Kebocoran Memori (*Memory Leak*) pada Playwright/Selenium 12

6 Lapisan Kecerdasan AI Deterministik & Agentic 13
6.1 Hermes Agent: Autonomous Query & Dorking Synthesis 13
6.2 JEV TypeSafe AI: Mengapa Bukan LLM Konvensional? 13

7 Matriks Perbandingan Arsitektur Master (15 Dimensi) 15

8 Kesimpulan & Prinsip Emas Rekayasa Sistem Harvester 15

1 Taksonomi & Spektrum Arsitektur Harvester Modern

Dunia otomasi web dan penarikan data internet telah berkembang jauh melampaui script sederhana berbasis pustaka `requests` atau `urllib`. Saat ini, arsitektur sistem pengambil data diklasifikasikan berdasarkan empat parameter fundamental:

1. **Latensi Toleransi:** Dari orde menit (perayapan artikel CPT) hingga orde milidetik (arbitrase harga CLOB dan pemantauan *mempool*).
2. **Tingkat Resistensi Target:** Dari situs tanpa proteksi hingga situs dengan WAF generasi terbaru (Cloudflare Turnstile, Cloudflare Managed Challenge, Datadome, Akamai BMP, PerimeterX/HUMAN).
3. **Karakteristik Data:** Teks statis/artikel panjang, struktur relasional/graf sosial, kedalaman buku pesanan (*order book depth*), atau status akun cerdas (*smart contract state*).
4. **Infrastruktur & Model Eksekusi:** *Batch CLI*, *Continuous Daemon*, *Event-Driven WebSocket/gRPC*, atau *Microservice API*.

Tiga Paradigma Besar Harvester Modern

- **Paradigma 1: Document & Social Graph Web Scrapers (High-Volume / High-Fidelity)**
  - *AITF Crawler Engine (Mas Anjas):* Model 2-tahap terpisah (*decoupled*). Tahap 1 menemukan tautan Google Search secara paralel via Selenium; Tahap 2 mengekstrak isi artikel via Playwright untuk membentuk dataset Markdown bersih tanpa *noise* boilerplate.
  - *CommunitEyes Pro Scraper:* Pemanen percakapan media sosial (X/Twitter) yang beroperasi 24/7 di VPS Ubuntu, mengumpulkan tweet dan relasi reply/retweet untuk analisis SNA (*Social Network Analysis*) menggunakan emulasi biometrik manusia tingkat lanjut.
- **Paradigma 2: Autonomous Anti-Bot Solving Microservice (Zero-Cost / High-Intelligence)**
  - *Bot KOMDIGI v1.1:* Layanan backend (FastAPI + SQLite Queue) yang bertugas menerima URL terkunci dan menyelesaikan 6 jenis CAPTCHA serta Cloudflare Turnstile menggunakan isolasi Google Chrome CDP murni di tingkat sistem operasi dan rangkaian *fallback* Vision LLM (Gemini 3.5 Flash Lite & Claude/DeepSeek).
- **Paradigma 3: Event-Driven High-Frequency Financial Harvesters (Sub-Second / High-Stakes)**
  - *Polymarket Arbitrage Harvester (`PolyBotNaulim` - VPS Dublin):* Sinkronisasi paralel antara penemuan kontrak (Gamma API), buku pesanan L2 (CLOB API), dan data harga spot instan (Binance WebSocket). Membutuhkan latensi $\leq$15 milidetik di zona netral regulasi (Dublin, Irlandia).
  - *Memecoin DEX & Solana Sniping Harvester (VPS Dublin):* Pemanen likuiditas instan yang membaca transaksi *mempool* langsung dari validator Solana via Geyser gRPC (<50 ms) serta mengevaluasi keamanan *smart contract* (anti-rug) dan sentimen media sosial dalam hitungan detik.

2 Lanskap Sistem Pertahanan Anti-Bot Modern (*The Defender's Weaponry*)

Untuk merancang arsitektur bot yang tangguh, seorang rekayasawan sistem wajib memahami secara presisi bagaimana pertahanan web modern bekerja. Sistem proteksi saat ini (Cloudflare, Akamai, Datadome, Kasada, PerimeterX) tidak lagi hanya memeriksa string `User-Agent`. Mereka menerapkan inspeksi berlapis dari level jaringan hingga biometrik.

Piramida Inspeksi Pertahanan Anti-Bot Web Modern

```
  [ Tingkat 5: Biometrik & Telemetri Perilaku ]
 (Kurva Mouse, Jeda Ketikan, Velocity Scroll, Focus DOM)
                      ^
                      |
  [ Tingkat 4: Tantangan Kriptografi / CAPTCHA ]
  (Cloudflare Turnstile, GeeTest v4, reCAPTCHA v2/v3, PoW)
                      ^
                      |
  [ Tingkat 3: Browser Environment & Sidik Jari DOM ]
(navigator.webdriver, Canvas 2D, WebGL Vendor, AudioContext)
                      ^
                      |
  [ Tingkat 2: Sidik Jari Protokol & TLS (Transport) ]
(JA3/JA3S/JA4 Hash, HTTP/2 SETTINGS & Priority Frames, TCP OS)
                      ^
                      |
  [ Tingkat 1: Reputasi Jaringan & Alamat IP (Network) ]
  (Klasifikasi ASN: Datacenter vs Residential, Geo-IP, AbuseIPDB)
```

2.1 Tingkat 1: Reputasi Jaringan & Klasifikasi IP

Setiap paket IP yang mencapai server web membawa informasi *Autonomous System Number* (ASN).

- **Datacenter IP (AWS, DigitalOcean, Hetzner, GCP):** Ditandai oleh WAF dengan skor kecurigaan tinggi. Jika sebuah IP AWS mencoba membuka halaman login Twitter atau Google Search, WAF langsung meluncurkan tantangan CAPTCHA atau memblokir koneksi dengan status `403 Forbidden`.
- **Residential & Mobile IP (Indihome, Telkomsel, Comcast, AT&T):** Memiliki skor kepercayaan tertinggi karena dialokasikan untuk pengguna rumahan dan ponsel pintar.
- **Geoblocking:** Server membatasi akses berdasarkan yurisdiksi kepatuhan hukum. Contohnya, Polymarket memblokir IP asal Amerika Serikat karena regulasi CFTC, sementara portal perbankan lokal sering memblokir IP dari luar Indonesia.

2.2 Tingkat 2: Sidik Jari Protokol & TLS (JA3, JA4, HTTP/2)

Bahkan sebelum sebuah baris HTML dikirimkan, WAF menganalisis proses *TLS Client Hello*:

- **JA3/JA4 Fingerprint:** Nilai hash yang dihitung dari urutan ciphersuite TLS, ekstensi TLS yang didukung, kurva eliptis, dan format titik yang dikirimkan oleh klien. Browser Google Chrome resmi menghasilkan tanda tangan JA3 yang sangat spesifik. Pustaka Python konvensional seperti pustaka `requests` atau `urllib` menggunakan modul OpenSSL default yang memiliki hash JA3 yang langsung teridentifikasi sebagai bot.
- **HTTP/2 Framing Fingerprint:** Struktur frame HTTP/2 awal (seperti nilai `SETTINGS_HEADER_TABLE_SI` `SETTINGS_MAX_CONCURRENT_STREAMS`, `WINDOW_UPDATE`, serta urutan pseudo-header `:method`,

`:authority, :scheme, :path`) dapat membedakan Chromium asli dengan klien HTTP otomasi buatan.

2.3 Tingkat 3: Sidik Jari Lingkungan Peramban (*Browser Environment Fingerprinting*)

Setelah koneksi TLS terbentuk dan JavaScript dieksekusi di peramban, script pelacak WAF memeriksa ratusan properti jendela peramban:

(a) **Kebocoran Flag Webdriver:** Peramban yang dikendalikan oleh Selenium atau Playwright secara default mengekspos properti `navigator.webdriver = true`. Selain itu, Selenium ChromeDriver sering kali menyisipkan variabel global internal seperti `window.$cdc_asdjflasutopfhvcZLm`

(b) **Sidik Jari Kanvas (Canvas 2D Fingerprinting):** Script WAF menggambar teks dan bentuk geometris tersembunyi pada elemen HTML5 Canvas, lalu membaca representasi data pikselnya menggunakan `toDataURL()`. Karena variasi arsitektur GPU, versi driver grafis, dan mesin rasterisasi font sistem operasi, setiap mesin menghasilkan hash piksel unik. Jika browser berjalan dalam mode *headless* tanpa GPU asli, hash kanvas akan bernilai seragam atau kosong, memicu bendera merah.

(c) **WebGL Vendor & Renderer:** Pemeriksaan terhadap konteks WebGL peramban. Jika nilainya menunjukkan `Google SwiftShader` atau `Mesa OffScreen`, WAF menyimpulkan bahwa peramban berjalan di atas emulasi perangkat lunak CPU (khas server Linux headless/CI/CD).

(d) **AudioContext Fingerprinting:** Membuat osilator audio di memori menggunakan Web Audio API dan mengukur dinamika gelombang suara tereduksi. Perbedaan arsitektur perangkat keras audio menghasilkan sidik jari akustik mesin.

2.4 Tingkat 4: Tantangan Kriptografi & Proof-of-Work (Cloudflare Turnstile)

Perlindungan modern seperti **Cloudflare Turnstile** telah meninggalkan model tebak gambar kotak konvensional. Sebagai gantinya, Turnstile menjalankan puzzle kriptografi *Proof-of-Work* (PoW) di latar belakang peramban:

- Skrip klien wajib memecahkan komputasi matematika rumit dalam durasi waktu tertentu sambil secara simultan mengumpulkan metrik lingkungan peramban.
- Jika hasil komputasi valid dan metrik peramban bersih, Turnstile secara otomatis menerbitkan token verifikasi (`cf-turnstile-response`).

2.5 Tingkat 5: Biometrik & Telemetri Perilaku (*Behavioral Telemetry*)

Platform dengan proteksi terketat di dunia (seperti X/Twitter, Google Search, dan LinkedIn) mengamati telemetri interaksi pengguna:

- **Lintasan Kursor Mouse:** Skrip pelacak merekam array koordinat (x, y, t). Otomasi dasar yang memindahkan kursor dalam garis lurus sempurna dengan kecepatan konstan langsung divonis sebagai bot.
- **Irama Pengetikan (Keystroke Dynamics):** Waktu jeda antara penekanan tombol (*flight time*) dan lama tombol ditahan (*dwell time*). Pengetikan instan atau jeda interval statis (misal tepat 100 ms) adalah ciri khas otomasi.
- **Dinamika Gulir (Scroll Dynamics):** Manusia menggulir halaman dengan inersia, akselerasi, deselerasi, dan sesekali menggulir balik ke atas (*reverse jitter*) saat membaca konten menarik.

3 Taktik & Rekayasa Penembusan Teruji (*The Attacker's Playbook*)

Berdasarkan analisis terhadap lima sistem riil yang dikaji, berikut adalah taktik rekayasa yang terbukti efektif menembus lapisan-lapisan pertahanan di atas:

3.1 Taktik 1: Subprocess Chrome CDP Isolation (Pelajaran dari Bot KOMDIGI)

Ini adalah solusi paling elegan untuk menembus Cloudflare Turnstile, GeeTest v4, dan WAF modern tanpa bergantung pada layanan solver berbayar atau memanggil model AI vision.

Prinsip Kerja Subprocess Chrome CDP

Alih-alih meluncurkan browser melalui pustaka otomasi seperti `webdriver.Chrome()` atau `chromium.launch()`, kita meluncurkan browser Google Chrome bawaan sistem operasi sebagai proses terpisah via sistem operasi dengan flag debugging aktif:

```
import subprocess
import time
from playwright.sync_api import sync_playwright

# 1. Jalankan Chrome resmi sistem operasi secara independen
cmd = [
    r"C:\Program Files\Google\Chrome\Application\chrome.exe",
    "--remote-debugging-port=9222",
    "--user-data-dir=C:\\Users\\Naufal
       Halim\\AppData\\Local\\Temp\\chrome_cdp_profile",
    "--no-first-run",
    "--no-default-browser-check"
]
proc = subprocess.Popen(cmd)
time.sleep(2)  # Beri waktu Chrome membuka socket debugging

# 2. Hubungkan Playwright ke browser via Chrome DevTools Protocol
   (CDP)
with sync_playwright() as p:
    browser = p.chromium.connect_over_cdp("http://localhost:9222")
    context = browser.contexts[0]
    page = context.pages[0] if context.pages else context.new_page()
    page.goto("https://target-berproteksi-turnstile.com")

    # Browser memiliki fingerprint 100% native:
    # navigator.webdriver bernilai undefined secara alami!
    page.wait_for_selector(".konten-rahasia", timeout=30000)

proc.terminate()
```

Keunggulan Utama: Karena peramban diluncurkan langsung oleh sistem operasi (bukan oleh driver otomasi), tidak ada jejak hooking Selenium, tidak ada variabel internal `$cdc_`, dan properti `navigator.webdriver` bernilai `undefined` secara native. Cloudflare Turnstile me-render centang hijau secara otomatis dalam 10–15 detik tanpa memerlukan intervensi klik tambahan.

3.2 Taktik 2: Virtual Framebuffer (`Xvfb`) & Non-Headless di VPS (Pelajaran dari AITF Mas Anjas)

Google Search mendeteksi dan memblokir browser dalam mode `headless: true`. Namun, server cloud (VPS Linux) umumnya tidak memiliki layar monitor fisik (*display monitor*).

Solusi Rekayasa AITF:

1. Menyetel konfigurasi internal peramban pada mode grafis penuh: `"headless": false`.
2. Menjalankan proses peramban di atas perangkat lunak peniru kartu grafis dan layar virtual Linux bernama **X Virtual Framebuffer** (`Xvfb`).
3. Perintah eksekusi: `xvfb-run -a -server-args="-screen 0 1920x1080x24" ./aitf-engine`.

Hasilnya: Browser Selenium meyakini dirinya sedang me-render antarmuka grafis di monitor 1080p dengan kedalaman warna 24-bit lengkap dengan konteks grafis, sehingga Google Search tidak mengklasifikasikannya sebagai instance headless scraping.

3.3 Taktik 3: Emulasi Biometrik Manusia & Kurva Bezier (Pelajaran dari CommunitEyes)

Untuk mengelabui analisis telemetri X/Twitter, modul `StealthBrowser` pada CommunitEyes Pro mengimplementasikan manipulasi kursor berbasis matematika kurva Bezier kubik:

Matematika Kurva Bezier untuk Pergerakan Kursor

Perpindahan kursor dari titik awal $P_0(x_0, y_0)$ ke titik target $P_3(x_3, y_3)$ tidak dilakukan secara linier, melainkan diinterpolasi melalui dua titik kontrol acak P_1 dan P_2:

$$B(t) = (1-t)^3 P_0 + 3(1-t)^2 t P_1 + 3(1-t) t^2 P_2 + t^3 P_3, \quad t \in [0, 1] \tag{1}$$

Dengan menambahkan variasi percepatan dan perlambatan acak pada parameter t, kursor bergerak melengkung secara luwes menyerupai tangan manusia nyata yang memegang mouse fisik.

Selain itu, modul menyertakan:

- **Pengetikan Berirama (*Human Typing*):** Menekan tombol satu per satu dengan jeda acak berdistribusi Gauss antara 30 hingga 120 milidetik per karakter.
- **Reverse-Scroll Jitter:** Probabilitas 30% untuk menggulir halaman sedikit ke atas (50–150 px) di tengah-tengah proses membaca, meniru manusia yang meninjau kembali gambar atau tweet sebelumnya.

3.4 Taktik 4: Manajemen Sesi & Injeksi Cookie Persisten (`x_state.json`)

Melakukan proses login (memasukkan username, password, dan OTP) secara berulang pada setiap siklus scraping adalah resep pasti untuk memicu penangguhan akun (*account ban*).

Solusi: Sesi autentikasi disimpan sekali dalam berkas terisolasi (`x_state.json`) yang mencakup cookies, token sesi (`auth_token`, `ct0`), serta *localStorage*. Saat instansiasi Playwright baru dimulai, berkas ini diinjeksikan secara instan melalui `browser.new_context(storage_state="x_state.json")`. Browser langsung mendarat pada beranda pengguna tanpa pernah melewati halaman formulir login.

3.5 Taktik 5: Vision LLM Triage Chain untuk CAPTCHA Visual (Pelajaran dari Bot KOMDIGI)

Ketika tantangan visual tak terhindarkan (seperti reCAPTCHA v2 gambar atau pertanyaan kalkulasi teks), Bot KOMDIGI menggunakan rantai penalaran multi-tingkat:

1. **Layer Triage (Regex Scoring):** Mengidentifikasi jenis CAPTCHA secara instan tanpa biaya token AI.
2. **Tingkat Utama (Gratis):** Mengirimkan gambar potongan CAPTCHA ke Google AI Studio **Gemini 3.5 Flash Lite** (kuota gratis 1.500 permintaan per hari) dengan prompt terstruktur ketat untuk menghasilkan indeks petak kotak gambar.
3. **Tingkat Cadangan (*Fallback*):** Jika kuota habis atau API mengembalikan galat `503`, sistem secara otomatis mengalihkan permintaan ke endpoint cadangan (Vikey.ai Claude Fable / DeepSeek v4.1).

4 Rekayasa Harvester Finansial Latensi Rendah (VPS Dublin)

Pada ranah perayapan data pasar keuangan terdesentralisasi (DEX dan pasar prediksi Polymarket), sasaran utamanya bukan lagi menghindari CAPTCHA visual, melainkan memenangkan **perlombaan latensi milidetik** dan menghindari serangan arbitrase jahat (*MEV Front-running*).

Perbandingan Arsitektur: Web Scraper Dokumen vs Harvester Finansial **Web Scraper Dokumen (AITF / CommunitEyes):**
Input Teks ⟶ DOM Rendering ⟶ HTML Cleaning ⟶ Disk Batch ⟶ **SLA: Menit**

Financial Market Harvester (Polymarket / Memecoin):
gRPC Mempool / WS Stream ⟶ Memory Parser ⟶ Delta Calc ⟶ Direct TX ⟶ **SLA: <50 Milidetik**

4.1 Strategi Penempatan Geografis & Jaringan (Kasus VPS Dublin)

Mengapa bot Polymarket (`PolyBotNaulim`) wajib ditempatkan di VPS Dublin (Irlandia)?

(a) **Geoblocking Compliance:** Polymarket secara ketat memblokir IP asal Amerika Serikat karena regulasi komisi perdagangan berjangka (CFTC). IP data center Irlandia (AWS region `eu-west-1` / Hetzner) memiliki status kepatuhan terbuka.

(b) **Pengurangan Round-Trip Time (RTT):**

- Jarak Jakarta ke Server CLOB Polymarket: ≈ 11.000 km ⟶ RTT fisik ≈ 250–350 milidetik.
- Jarak VPS Dublin ke Server CLOB Polymarket: ≈ Local peering ⟶ RTT fisik ≈ **8–18 milidetik**.

Pada pasar prediksi berdurasi 5 menit (`btc-up-or-down-5m`), selisih latensi 300 ms adalah pembeda mutlak antara mendapatkan harga eksekusi terbaik (*maker/taker spread*) atau mengalami kegagalan transaksi (*slippage out of bounds*).

4.2 Arsitektur Ingesti Dual-Stream Polymarket

Harvester Polymarket mengombinasikan dua metode penarikan data:

- **Stream 1: Polling Penemuan Pasar (Gamma REST API):** Mengecek setiap 5 menit untuk menemukan kontrak pasar yang baru dibuka:

```
# Identifikasi token biner Up / Down aktif
params = {"limit": 10, "active": "true", "archived": "false", "slug":
    "btc-up-or-down-5m"}
resp = await client.get("https://gamma-api.polymarket.com/events",
    params=params)
up_token_id, down_token_id = parse_clob_tokens(resp.json())
```

- **Stream 2: Pemanenan Buku Pesanan L2 Real-Time (CLOB API):** Mengambil kedalaman harga penawaran (*bids*) dan permintaan (*asks*) secara asinkron.
- **Mitigasi Galat 404 pada Token Tidak Likuid:** Sering kali Gamma API telah merilis token ID baru, namun buku pesanan pada CLOB belum diinisialisasi oleh *market maker*. Harvester yang naif akan mengalami crash akibat pengecualian `HTTP 404`. Bot `PolyBotNaulim` mengisolasi status ini secara tertutup (*silent catch*), menandai pasar sebagai *pending liquidity*, dan mengandalkan data harga spot eksternal (Binance WebSocket) sebagai acuan nilai wajar awal (*fair value benchmark*).

4.3 Pemanenan Likuiditas Mempool Solana & Pertahanan Anti-MEV

Pada bot memecoin jaringan Solana, harvester tidak menggunakan HTTP REST konvensional karena terlalu lambat (latensi 500–1.000 ms).

Arsitektur Streaming Mempool via Geyser gRPC

Harvester membuka koneksi streaming biner gRPC langsung ke plugin **Geyser** pada validator Solana:

1. **Sub-50ms Event Streaming:** Setiap instruksi pembuatan pool baru pada protokol Raydium atau Pump.fun terbaca saat transaksi masih berada di antrean mempool sebelum blok resmi difinalisasi.
2. **Automated Contract Safety Audit (Rug-Check):** Sebelum mengeksekusi pembelian, modul validasi membaca struktur byte akun token untuk memastikan:
   - `Mint Authority` telah dinonaktifkan (*revoked*).
   - `Freeze Authority` telah dinonaktifkan (koin tidak dapat dibekukan sepihak).
   - Token likuiditas LP telah dibakar (*burned*) atau dikunci di kontrak waktu.
   - 10 dompet pemegang terbesar tidak menguasai lebih dari 25% suplai.
3. **Pertahanan Anti-MEV via Private Jito RPC Bundles:** Transaksi pembelian tidak dikirim ke mempool publik (tempat di mana bot pemangsa dapat menyelipkan transaksi di depan dan di belakang kita, dikenal sebagai *sandwich attack*). Transaksi dikemas dalam bundel terenkripsi dan dikirim langsung ke validator Jito disertai biaya tip penambang (*Jito tip*).

5 Komplikasi Lapangan & Solusi Praktis (*Battle Scars & Fixes*)

Dalam operasional produksi skala penuh, berbagai kendala tak terduga kerap kali menghentikan operasional bot. Tabel dan penjelasan berikut merangkum solusi teknis terhadap insiden-insiden yang paling sering terjadi:

5.1 Tabel Diagnostik Masalah & Solusi Rekayasa

Gejala / Masalah	Penyebab Akar (Root Cause)	Solusi Rekayasa Teruji
Google Block / re-CAPTCHA Trigger	Pola kueri terlalu cepat atau IP terdeteksi sebagai scraping headless.	Pisahkan proses ke model 2-tahap (seperti AITF); gunakan `Xvfb`; integrasikan rotasi IP residential.
Cloudflare 429 Too Many Requests	WAF membatasi laju permohonan HTTP karena lonjakan frekuensi.	Implementasikan algoritma *Exponential Backoff with Full Jitter*; kurangi konkurensi worker.
Cloudflare Turnstile Infinite Spin	Properti `navigator.webdriver` terdeteksi oleh skrip tantangan Turnstile.	Beralih ke **Subprocess Chrome CDP Isolation** (Bot KOMDIGI) agar menggunakan Chrome asli OS.
X/Twitter Shadowban & Suspensi Akun	Pergerakan mouse linier instan atau interval ketikan statis terdeteksi bot.	Terapkan kurva Bezier kubik; variasikan pengetikan 30–120 ms; persistensi sesi via `x_state.json`.
Memory Leak pada Browser Panjang	Browser Chromium mengakumulasi cache render, V8 heap, dan DOM zombie.	Lakukan *Graceful Browser Recycling*: tutup dan buat ulang instans peramban setiap 100 URL.
WebSocket Desync & Reconnection Storm	Koneksi soket terputus hening tanpa memicu event galat TCP resmi.	Kirim ping/pong heartbeat setiap 15 detik; jika tak ada balasan dalam 5 detik, paksa re-koneksi dengan jitter.
Boilerplate Noise pada Dataset CPT	Selektor statis mengambil menu navigasi, iklan, footer, dan komentar.	Ganti selektor CSS `"body p"` dengan pustaka analisis algoritma densitas teks **trafilatura**.
Data Poisoning / Duplikasi Teks	Banyak artikel berita sindikasi memiliki isi identik pada URL berbeda.	Terapkan deduplikasi berbasis hash **MinHash LSH** sebelum menyimpan dokumen ke korpus akhir.

Table 1: Matriks Diagnostik Masalah Lapangan dan Solusi Rekayasa Teruji

5.2 Pembedahan Masalah Spesifik & Solusi Kode

5.2.1 1. Algoritma Exponential Backoff dengan Full Jitter

Saat menghadapi pembatasan laju (*rate limiting*) HTTP 429, algoritma tidur statis (`time.sleep(5)`) justru memperburuk keadaan karena semua worker akan terbangun pada detik yang sama dan kembali membombardir server target (*thundering herd problem*).

```
import asyncio
import random
```

```python
async def fetch_with_backoff(client, url, max_retries=5, base_delay=1.0,
    max_delay=32.0):
    for attempt in range(max_retries):
        try:
            response = await client.get(url)
            if response.status_code == 429:
                # Full Jitter Formula: sleep_time = Uniform(0,
                    min(max_delay, base * 2^attempt))
                delay = random.uniform(0, min(max_delay, base_delay * (2
                    ** attempt)))
                print(f"[429 Rate Limited] Mundur {delay:.2f} detik
                    (Percobaan {attempt + 1})")
                await asyncio.sleep(delay)
                continue
            response.raise_for_status()
            return response
        except Exception as e:
            if attempt == max_retries - 1:
                raise e
            await asyncio.sleep(random.uniform(1.0, 3.0))
```

5.2.2 2. Penanganan Kebocoran Memori (*Memory Leak*) pada Playwright/Selenium

Ketika peramban membuka ratusan halaman secara terus-menerus, memori RAM sistem operasi akan membengkak dari 200 MB hingga melebihi 4 GB, memicu pemutusan paksa oleh kernel (*OOM Killer*).

Pola Rekayasa Solusi: Recycle Pattern

```python
async def robust_batch_crawler(url_list, batch_size=50):
    for i in range(0, len(url_list), batch_size):
        chunk = url_list[i : i + batch_size]
        # Inisialisasi instance browser baru untuk setiap batch 50 URL
        async with async_playwright() as p:
            browser = await p.chromium.launch(headless=True)
            context = await browser.new_context()

            tasks = [scrape_page(context, url) for url in chunk]
            await asyncio.gather(*tasks)

            # Menutup browser akan membersihkan seluruh V8 heap dan
                socket zombie di OS
            await context.close()
            await browser.close()
```

6 Lapisan Kecerdasan AI Deterministik & Agentic

Dua inovasi mutakhir yang diadopsi dari portofolio riset Anda adalah penggabungan **Hermes Agent** (perencana kognitif otonom di hulu) dan **JEV TypeSafe AI System One** (gerbang deterministik berlatensi ultra-cepat di hilir).

Pipeline Harvester Generasi Baru: The Agentic CPT Harvester [**Tema / Riset CPT**] $\longrightarrow$
Hermes Agent Planner $\longrightarrow$ 50+ Targeted Google Dorks
$\downarrow$
[**Tahap Discovery**] $\longrightarrow$ **AITF Engine** (Parallel 3, Xvfb Stealth) $\longrightarrow$ `crawler_url.txt`
$\downarrow$
[**Tahap Extraction**] $\longrightarrow$ **Async Playwright + Trafilatura** $\longrightarrow$ Raw Markdown Clean Content
$\downarrow$
[**Tahap Quality Gate**] $\longrightarrow$ **JEV TypeSafe AI (<200ms)**

$$\begin{cases} \text{choice(structure)} == \text{'valid_article'} \\ \text{noul(is_cpt_worthy)} == \text{True} \\ \text{score(quality_index)} \geq 0.70 \end{cases}$$

$\downarrow$
[**Dataset Final**] $\longleftarrow$ Teks Terverifikasi Bebas Sampah Masuk ke `dataset_cpt_final.md`

6.1 Hermes Agent: Autonomous Query & Dorking Synthesis

Masalah mendasar pada crawler konvensional adalah ketergantungannya pada daftar kata kunci statis yang diisi manual oleh manusia di `daftar_keyword.txt`.

Hermes Agent bertindak sebagai otak hulu:

- Menerima arahan level tinggi, contoh: *"Kumpulkan regulasi kecerdasan buatan dan tata kelola data di Indonesia"*.
- Secara dinamis menyusun 50+ kueri pencarian berakurasi tinggi menggunakan operator lanjutan Google (*Google Dorking*):
  - `site:komdigi.go.id "kecerdasan artifisial" filetype:pdf`
  - `site:brin.go.id intitle:"tata kelola data" 2024..2026`
  - `site:jdih.*.go.id "perlindungan data pribadi" uu`
- Menginjeksikan daftar kueri tersebut langsung ke pipeline penemuan tanpa campur tangan operator.

6.2 JEV TypeSafe AI: Mengapa Bukan LLM Konvensional?

Pada fase pasca-ekstraksi, menyaring apakah suatu teks layak masuk ke dataset pelatihan model bahasa (CPT) sangat krusial. Menggunakan model LLM teks konvensional (seperti GPT-4 atau Llama-3) untuk memfilter 10.000 halaman web memiliki tiga cacat fatal:

1. **Latensi Tinggi:** Rata-rata 2 hingga 5 detik per panggilan API.
2. **Biaya Komputasi Mahal:** Membutuhkan jutaan token per hari.
3. **Halusinasi Probabilistik:** Format keluaran sering berubah-ubah (kadang membalas dengan penjelasan basa-basi di luar format JSON).

Solusi: JEV System One (`https://api.typesafe.ai/v1/systemone`) JEV adalah mesin inferensi keputusan deterministik berbasis kontrak tipe data yang beroperasi pada latensi di bawah 200 milidetik:

Tiga Kontrak Operasi Utama JEV System One

1. **Operasi `choice`:** Mengklasifikasikan struktur halaman ke dalam himpunan kategori ketat tanpa teks tambahan:

$$\text{JEV.choice}(\text{text}, \{\text{"valid_article"}, \text{"nav_dump"}, \text{"paywall"}, \text{"spam_ad"}\}) \tag{2}$$

2. **Operasi `noul`:** Evaluasi kondisi Boolean biner (`True` / `False`):

$$\text{JEV.noul}(\text{"Apakah teks ini mengandung analisis faktual dan informatif untuk pelatihan AI?"}, \text{text}) \tag{3}$$

3. **Operasi `score`:** Menghitung bobot kualitas teks dalam rentang numerik pasti:

$$\text{JEV.score}(\text{"Kepadatan informasi ensiklopedis vs promosi komersial"}, \text{text}) \in [0.0, 1.0] \tag{4}$$

7 Matriks Perbandingan Arsitektur Master (15 Dimensi)

Dimensi	AITF (Anjas)	Bot KOMDIGI	CommunitEyes	PolyBot Dublin	Memecoin Bot
1. Fokus Inti	Dataset CPT Google	Solver CAPTCHA	SNA Graf X.com	Arbitrase Prediksi	Sniping Likuiditas
2. Model Alur	2-Stage CLI Batch	Persistent Microservice	Distributed Daemon	Realtime Async Loop	gRPC Event Stream
3. Toleransi Latensi	Menit (sangat santai)	9–78 detik	30 menit (terjadwal)	<100 ms (sangat ketat)	<50 ms (ekstrem)
4. Runtime Engine	Selenium + Playwright	Playwright + CDP	Playwright Chromium	Python asyncio+httpx	Rust/Python Async
5. Memory Footprint	Sangat bersih (lepas)	≈ 300 MB	Diisolasi di VPS	Sangat hemat (<40MB)	Sangat hemat (<50MB)
6. Taktik Anti-Bot	Non-headless + Xvfb	Native Chrome CDP	Bezier + Sesi JSON	WAF Backoff + Geo	Anti-MEV Jito Bundles
7. Peran AI	Dataset untuk AI	Gemini 3.5 Vision	Heuristik Hermes	Model Fair Value	Model Sentimen MTProto
8. Format Data	Markdown murni	JSON SolveAttempt	SNA Graph JSON	L2 Order Book JSON	Binary RPC Logs
9. Geolocation	Bebas (Lokal)	Bebas (Lokal)	Bebas (VPS)	Wajib VPS Dublin	Dekat Node Validator
10. Konkurensi	Hybrid (P1:3, P2:1)	Antrean tunggal	Single worker loop	Multi-stream paralel	WebSocket paralel
11. Error Handling	Catat ke `.log`	Auto Re-queue 15s	Log	Retry, CLOB fallback	Drop koin gagal
12. Ingest Inbound	Berkas lokal teks	HTTP POST API	Webhook Cloudflare	REST Polling	gRPC/WebSocket
13. State Storage	Stateless (file teks)	Session folder	`x_state.json`	Memory state bot	Mempool cache
14. Skalabilitas	Multi-instance lokal	Microservice Horisontal	Multi-VPS Agent	Multi-market worker	Dedicated RPC node
15. Aksi Pasca-Data	Tulis dataset CPT	Balas solusi token	Analisis Graf SNA	Eksekusi Order CLOB	Swap Token via Jito

Table 2: Matriks Perbandingan Komparatif Menyeluruh Kelima Sistem Pemanen Data

8 Kesimpulan & Prinsip Emas Rekayasa Sistem Harvester

Berdasarkan telaah mendalam terhadap kelima sistem dan integrasi teknologi modern, terdapat lima prinsip emas yang dapat menjadi pedoman dalam membangun sistem perayapan dan pemanenan data masa depan:

Lima Prinsip Emas Rekayasa Sistem Harvester Modern

1. **Pemisahan Kekhawatiran (*Separation of Concerns*):** Jangan pernah menggabungkan fase penemuan URL (*discovery*) dengan fase ekstraksi konten (*content extraction*) dalam satu thread tunggal. Pemisahan seperti pada AITF Crawler Engine menjaga agar pemblokiran IP pada mesin pencari tidak menghentikan proses pengunduhan konten web yang sudah terdaftar.
2. **Gunakan Browser Asli OS Sebelum Menyerah ke Layanan Berbayar:** Inovasi Subprocess Chrome CDP dari Bot KOMDIGI membuktikan bahwa menjalankan Google Chrome resmi dengan profil mandiri mampu menembus Cloudflare Turnstile secara gratis dan 100% andal tanpa memerlukan solver pihak ketiga.
3. **Latensi Menentukan Lokasi Infrastruktur:** Untuk kebutuhan pasar finansial (Polymarket dan DEX), kecepatan cahaya di serat optik adalah batasan nyata. Menempatkan server di VPS Dublin atau lokasi terdekat dengan simpul pertukaran data adalah keharusan mutlak yang tidak dapat dikompensasi oleh optimasi kode apa pun di Indonesia.
4. **Hindari Halusinasi Probabilistik di Gerbang Validasi:** Gunakan mesin keputusan deterministik bertipe data ketat seperti **JEV TypeSafe AI** untuk validasi data skala besar. Hal ini memangkas biaya komputasi hingga 90% dan menjamin stabilitas format dataset.
5. **Pertahanan Anti-Bot Adalah Permainan Perlindungan Lapisan:** Tidak ada satu trik ajaib untuk melewati proteksi web. Sistem yang tangguh mengombinasikan reputasi IP yang bersih, penyamaran sidik jari TLS/JA4, eliminasi flag webdriver, dan emulasi biometrik manusia yang luwes.

Dokumen ini diharapkan menjadi rujukan komprehensif bagi Anda dalam merancang, memperbaiki, dan mengoperasikan armada bot otomasi di berbagai domain rekayasa perangkat lunak.